

Apresentação final do Módulo 1 — objetivo e estrutura

E4.6 · Dia 4, 3 de setembro de 2026 · 5 minutos por equipe

A apresentação final não é um relatório técnico: é a especificação de um sistema. Em cinco minutos, cada equipe diz para que serve o sistema que quer desenvolver, quais ações dá para executar de verdade para chegar lá, quais dados existem para informar essas ações e se eles são relevantes para a informação que elas exigem, que análise se faz com eles, o que o sistema significa para quem é afetado por ele, e quem decide o quê lá dentro. Os seis blocos se apresentam nesta ordem: cada um só faz sentido em função do primeiro.

Especifiquem o máximo que conseguirem — não é preciso responder a tudo. Um campo que fique em branco é informação, não falha: vale mais dizer isso em voz alta do que preenchê-lo com o que vocês gostariam que fosse verdade. Mas quanto mais fundo levarem esta especificação, melhor preparados chegam ao que vem depois — é este documento que continua no Módulo 2 e no Projeto de Aplicação Prática, e o trabalho feito aqui é trabalho que não vão precisar fazer lá.

1 · O objetivo

Para que serve o sistema que vocês querem desenvolver?

O propósito do sistema em uma frase: a função que ele cumpre na operação e para quem, não a tecnologia com que é feito. Digam o que deixaria de ser feito se ele não existisse, o que ele explicitamente não se propõe a fazer, e por qual critério se saberá que está servindo — em reais, horas ou pontos de OTIF, não em pontos de acurácia.

2 · As ações

O que é que, realisticamente, dá para executar para cumprir esse propósito?

As ações que a organização consegue mesmo executar — não as desejáveis: quem as executa, com que frequência, com qual mandato, orçamento e sistemas já instalados. Uma ação que exige autoridade, dinheiro ou integração que vocês não têm não conta: listem essa ação à parte, com o que precisaria mudar para ela passar a contar. Se nenhuma ação realista mudar por causa do sistema, o propósito do bloco 1 não se alcança por este caminho — e é isso que vocês precisam dizer.

3 · Os dados que informam as ações *quais dados existem mesmo e a quais vocês têm acesso hoje — e, para cada fonte, as quatro perguntas*

3.1 · A alegação — quem
Quem afirma o quê, e com qual autoridade?

Cada campo tem um autor: um sistema, um sensor, um motorista, um cliente, um fornecedor. Digam quem produz o dado e qual interesse essa pessoa tem no valor que registra — quem é medido pelo número raramente é neutro ao registrá-lo.

3.2 · A adequação — como
Estes dados carregam a informação de que as ações precisam?

Digam primeiro qual informação as ações do bloco 2 exigem; depois, se estes dados carregam essa informação. Como foi medido, com qual granularidade, cobertura e latência — e se isso chega no momento em que a ação precisa ser executada. Não existe dado bom em abstrato: só dado que serve, ou não serve, para uma ação nomeada.

3.3 · A proveniência
Por onde ele passou até chegar aqui?

Origem, sistemas atravessados, transformações e cruzamentos, quem tem acesso e desde quando. Havendo dados pessoais, a base legal prevista na LGPD e o prazo de retenção.

3.4 · A curadoria
O que foi decidido sobre os dados — e por quem?

As regras de limpeza, exclusão, imputação e definição de KPI que vocês aplicaram, cada uma com um dono. Toda exclusão é uma escolha: mostrem o número antes e depois dela. É a diferença entre um dado tratado e um dado maquiado.

4 · A análise *o que o sistema faz com os dados, e como vocês sabem que serve*

4.1 · A adequação da análise
Por que este método serve a este propósito?

A abordagem que o sistema usa — regra, otimização, modelo ou nada — e a justificativa da escolha. Como vocês estabelecem a adequação: a métrica, a linha de base com que comparam, o custo em reais de cada tipo de erro, e o que fizeram para descartar fuga de dados. Uma análise adequada é a que falharia de forma visível se estivesse errada.

4.2 · A gestão
Quem mantém o sistema vivo depois do piloto?

Dono nomeado, cadência de revalidação, monitoramento de deriva e portões go/no-go com datas. E a condição de desistência: o que precisaria ser verdade para vocês desligarem o sistema.

5 · A ética, nesta aplicação
Quem é afetado por este sistema e não está nesta sala?

Não a ética em geral: a desta aplicação concreta. Quem colhe o benefício e quem carrega o risco — motoristas, passageiros, clientes, terceiros — e o que acontece com essas pessoas quando o sistema funciona exatamente como foi desenhado, não só quando falha. Digam o que seria legal e ainda assim errado, o que essas pessoas saberiam se alguém explicasse o sistema a elas, e qual recurso elas têm quando discordarem dele. Cumprir a LGPD é o mínimo, não a resposta.

6 · A configuração da decisão
Dentro do sistema, quem decide o quê — pessoa ou agente de IA?

Para cada passo do fluxo do sistema: quem propõe, quem decide, quem pode reverter e em qual prazo. Digam explicitamente o que fica automático, o que fica com humano no circuito e o que nunca sai de mãos humanas — e a razão de cada fronteira. Onde um agente de IA decidir, digam o que acontece quando ele erra e quem percebe a falha.

Avaliação por pares, 1–5: clareza do problema · realismo dos dados · qualidade da avaliação · tratamento de riscos · viabilidade. Duas perguntas por apresentação, uma dos colegas e uma do formador. Avalia-se a qualidade do raciocínio, não a sofisticação técnica: concluir “isto não precisa de IA, precisa de uma regra e de um dono” é uma resposta forte.

Os termos desta especificação, definidos

Anexo do E4.6 · para consultar enquanto preenchem os seis blocos

Estas definições são para consultar **enquanto** preenchem os seis blocos, não para decorar antes. Servem sobretudo para poderem discordar de quem usar uma destas palavras sem dizer o que quer dizer com ela. Cada entrada traz o que o termo significa, quem o definiu assim, e o que ele exige de vocês nesta apresentação. Onde não existe definição canônica na literatura, a entrada diz isso. As referências completas estão no fim.

1 · O objetivo

Propósito, e a fronteira do sistema (*problem framing*) — a função que o sistema cumpre, e onde ele termina. Selbst e colegas mostram que boa parte das falhas de sistemas algorítmicos vem de traçar essa fronteira estreita demais: avalia-se o modelo e não o sistema sociotécnico de que ele faz parte, no que chamam a armadilha do enquadramento (*Selbst et al. 2019*). **Nesta apresentação:** é por isso que o bloco 1 pede também o que o sistema **não** se propõe a fazer. Um propósito sem fronteira não é especificável.

Indicador, ou KPI (*key performance indicator*) — a quantidade escolhida para representar o desempenho de uma operação. Não tem definição acadêmica canônica: é uma decisão de gestão, não um fato dos dados. O que está estabelecido é o efeito colateral. Ridgway reuniu casos em que a introdução de um indicador quantitativo passou a distorcer o comportamento de quem era medido por ele (*Ridgway 1956*). **Nesta apresentação:** o critério do bloco 1 é um KPI. Digam quem o define e onde isso está escrito.

OTIF (*on time in full*) — a proporção de entregas feitas no prazo e completas. Não tem definição normalizada: a tolerância, o tratamento das ocorrências e a unidade de contagem (viagem, valor de frete, cliente) mudam de empresa para empresa.

Nesta apresentação: o E1.1 produziu nove OTIF diferentes sobre os mesmos dados. Se usarem OTIF como critério, digam qual dos nove.

Acurácia (*accuracy*) — a fração de todas as previsões que estão certas. Sobe sozinha quando uma classe é muito mais frequente do que a outra, e por isso engana em problemas desequilibrados (*Fawcett 2006; He & Garcia 2009*). **Nesta apresentação:** o bloco 1 não a aceita como critério de sucesso, porque um ponto de acurácia não diz a quem aprova o orçamento o que muda na operação.

2 · As ações

Decisão informada por dados (*data-driven decision making*) — decidir a partir da análise em vez de só da intuição. Provost e Fawcett insistem em que o valor não está na análise, e sim na decisão que ela muda (*Provost & Fawcett 2013a*). **Nesta apresentação:** é o que o bloco 2 testa. Se nenhuma decisão muda, a análise não tem por onde produzir valor, e vale mais dizê-lo do que inventar uma ação.

Mandato, e prestação de contas (*accountability*) — uma relação em que alguém tem a obrigação de explicar e justificar a sua conduta perante um fórum que pode questioná-la, e da qual decorrem consequências (*Bovens 2007*). **Nesta apresentação:** é isto que «dono nomeado» quer dizer: não quem executa, mas quem responde. Um dono sem fórum e sem consequência não é um dono.

3 · Os dados

Qualidade de dados, ou adequação ao uso (*data quality, fitness for use*) — dados têm qualidade quando servem ao uso a que se destinam. Não existe qualidade em abstrato. Wang e Strong estabeleceram empiricamente as dimensões que os consumidores de dados de fato usam, entre elas relevância, completude, tempestividade, credibilidade e interpretabilidade (*Wang & Strong 1996*). **Nesta apresentação:** daí a ordem dos blocos. O 3.2 só tem resposta depois de o bloco 2 nomear a ação.

Autoria do dado — cada campo é uma alegação feita por alguém. Não há aqui um termo técnico consagrado, e é por isso que a pergunta passa despercebida com tanta facilidade. Vale aqui o mecanismo da entrada sobre KPI: quem é avaliado pelo número raramente é neutro ao registrá-lo (*Ridgway 1956*). **Nesta apresentação:** para cada fonte do 3.1, digam quem produz o dado e que interesse essa pessoa tem no valor que registra.

Unidade de análise (*unit of analysis*) — a entidade sobre a qual vocês decidem e concluem: a entrega, o veículo, a rota, o cliente, o mês. Não vem dos dados. É uma escolha do desenho, e fixa o que conta como um caso. Robinson mostrou que uma correlação medida entre agregados não vale para os indivíduos que os compõem, a chamada falácia ecológica (*Robinson 1950*). **Nesta apresentação:** a unidade de análise tem de ser a da ação do bloco 2. Se a ação se executa por veículo em rota e a conclusão foi tirada por cliente/mês, não é a mesma coisa dita de duas maneiras: é uma conclusão que não se aplica à ação.

Granularidade, ou grão (*granularity, grain*) — o nível de detalhe em que cada linha é registrada. Em modelagem dimensional, declarar o grão (dizer o que exatamente uma linha representa) é o passo que precede a escolha de qualquer métrica ou dimensão (*Kimball & Ross 2013*). **Não é sinônimo de unidade de análise:** o grão é o que existe nos dados, a unidade de análise é o que vocês escolhem para decidir. E o grão só agrega para cima, nunca para baixo: o que não foi registrado fino não se recupera depois. Vale a pena separar quatro eixos, que variam de forma independente:

Temporal — de quanto em quanto tempo o dado é registrado: a cada ping de telemetria, por evento de checkpoint, por viagem, por dia, por mês fechado. Agregar no tempo muda o próprio resultado. Em previsão de demanda, o nível de agregação em que se prevê altera sistematicamente a acurácia (*Nikolopoulos et al. 2011*). Separem três frequências que raramente coincidem: a de **coleta**, a de **atualização** do sistema e a de **relato** a quem decide. Manda a mais lenta das três.

Espacial — a que unidade geográfica o dado está preso: coordenada, trecho, praça de pedágio, cidade, região, malha. Openshaw mostrou que os resultados estatísticos mudam conforme as fronteiras e a escala escolhidas, sem que nada tenha mudado no terreno; é o problema da unidade de área modificável (*Openshaw 1984*). Duas equipes com os mesmos dados e recortes diferentes chegam a números diferentes, e nenhuma das duas errou a conta.

De entidade — onde a linha cai na hierarquia da operação: etapa, entrega, viagem, rota, contrato, cliente, praça. Aqui a agregação passa despercebida, porque o número continua a fazer sentido depois de subir um nível. Só deixou de responder à mesma pergunta.

De atributo — quantos níveis tem um campo codificado: *motivo_atraso* com seis códigos ou com sessenta; «teve ocorrência, sim ou não» ou o tipo de ocorrência. Grosso demais não sustenta a ação. Fino demais não é preenchido com seriedade por quem o registra, e a granularidade vira ruído.

Nesta apresentação: para cada fonte do bloco 3, digam o grão nos quatro eixos e a unidade de análise da decisão que ele informa. Uma entrega, um veículo em rota e o OTIF do mês do cliente são três grãos do mesmo problema, e uma ação desenhada para um não se executa no outro.

Cobertura e latência (*coverage; timeliness*) — quanto do universo de interesse o dado abrange, e quanto tempo passa entre o fato acontecer e o dado estar disponível; correspondem à completude e à tempestividade nas dimensões de qualidade de dados (Wang & Strong 1996). Latência não é granularidade temporal: a granularidade é de quanto em quanto tempo se registra, a latência é quanto tempo passa até o registro estar disponível. Um dado pode ser de minuto a minuto e chegar com dois dias de atraso. **Nesta apresentação:** um dado que chega depois de a ação ter de ser executada vale zero para essa ação, por melhor que seja. Digam a latência em horas, não em adjetivos.

Proveniência (*data provenance, lineage*) — o registro da origem de um dado e do caminho que ele percorreu: de onde veio, por que transformações passou, e por que está aqui com este valor (Buneman, Khanna & Tan 2001; W3C PROV-DM 2013).

Nesta apresentação: se ninguém souber responder «por onde passou», o dado não é auditável, e uma decisão que se apoie nele não resiste a ser contestada.

Curadoria (*data curation*) — o conjunto de decisões humanas aplicadas aos dados antes de qualquer análise: o que se limpa, o que se exclui, o que se imputa, como se define cada indicador. Não tem definição canônica única. A consequência, essa, é sempre a mesma: toda exclusão é uma escolha, e toda escolha tem autor. **Nesta apresentação:** mostrem o número antes e depois de cada regra. É a diferença entre um dado tratado e um dado maquiado.

Dados em falta, e imputação (*missing data; imputation*) — imputar é substituir um valor ausente por um valor estimado. Rubin mostrou que o que se pode fazer legitimamente depende do **mecanismo** que gerou a ausência: se ela é aleatória, se depende dos dados observados, ou se depende do próprio valor que falta (Rubin 1976; Little & Rubin 2019). **Cuidado:** o caso que dói é o terceiro, quando o dado falta **porque** o valor era ruim. **Nesta apresentação:** excluir essas linhas melhora o indicador e piora a operação.

Dado pessoal, e base legal (*personal data; legal basis*) — dado pessoal é o que identifica ou torna identificável uma pessoa natural. Tratá-lo exige enquadrar-se em uma das dez hipóteses do art. 7.º da LGPD e, tratando-se de dado sensível, no rol mais restrito do art. 11 (*Lei n.º 13.709/2018*). **Nesta apresentação:** o consentimento é uma das dez, não a regra. Digam qual é a de vocês, fonte a fonte.

Prazo de retenção (*retention period*) — por quanto tempo o dado pode ser conservado. A LGPD manda eliminá-lo após o término do tratamento, com exceções tipificadas: obrigação legal, pesquisa com anonimização, transferência a terceiro nos termos da lei, e uso exclusivo do controlador com dados anonimizados (*art. 16 da Lei n.º 13.709/2018*). **Nesta apresentação:** «guardamos tudo, por via das dúvidas» não é uma resposta ao 3.3; é a ausência de uma.

4 • A análise

Regra, otimização e modelo — três abordagens diferentes: uma **regra** fixa uma condição decidida por pessoas; uma **otimização** escolhe a melhor ação sujeita a restrições declaradas; um **modelo** estima uma quantidade desconhecida a partir de exemplos (Provost & Fawcett 2013b). **Nesta apresentação:** a pergunta do 4.1 não é qual é a melhor, é por que esta. Concluir que uma regra basta é uma resposta forte.

Linha de base (*baseline*) — o desempenho de uma regra trivial, contra a qual qualquer sistema tem de ser comparado antes de ser considerado útil; Hand mostra que boa parte do progresso reportado desaparece quando essa comparação é feita (Hand 2006). **Nesta apresentação:** sem linha de base, o número do bloco 4 não é avaliável. Digam sempre contra o quê.

Custo esperado (*expected cost, cost-sensitive learning*) — avaliar uma política pelo custo total que ela gera, atribuindo um custo a cada tipo de erro, em vez de por uma taxa de acerto (Elkan 2001). **Nesta apresentação:** é a única métrica em reais, e por isso a única que o conselho lê sem tradução. Peçam sempre, junto com ela, quanto custa **não fazer nada**.

Fuga de dados (*data leakage*) — usar, para treinar ou avaliar, informação que não estaria disponível no momento em que a decisão tem de ser tomada, ou que já viu o conjunto de teste (Kaufman et al. 2012); um levantamento recente cataloga oito tipos e encontra-os em 294 artigos de 17 áreas científicas (Kapoor & Narayanan 2023). **Nesta apresentação:** o teste é uma pergunta só — **este campo existia antes da decisão?** Se não, sai.

Deriva (*concept drift, dataset shift*) — a relação entre as variáveis e o alvo muda ao longo do tempo, e o sistema degrada-se sem que ninguém lhe tenha tocado (Gama et al. 2014). **Nesta apresentação:** o bloco 4.2 existe por causa disto. Um sistema sem cadência de revalidação tem prazo de validade, e ninguém sabe qual é.

Portão go/no-go (*stage-gate*) — ponto de decisão marcado com data em que um critério definido de antemão determina se o projeto continua, muda ou para (Cooper 1990). **Nesta apresentação:** um portão sem critério escrito antes e sem data no calendário é uma reunião. Digam as duas coisas.

5 • A ética, nesta aplicação

Sistema sociotécnico (*sociotechnical system*) — o sistema é o modelo mais as pessoas, os procedimentos e as instituições em que ele opera; avaliar só a parte técnica é a armadilha do enquadramento, e é ela que faz um sistema tecnicamente correto produzir dano (Selbst et al. 2019). **Nesta apresentação:** é por isso que o bloco 5 pergunta o que acontece quando o sistema funciona **como foi desenhado**, e não só quando falha.

Recurso, e devido processo (*recourse, due process*) — a possibilidade concreta de uma pessoa afetada saber que foi avaliada, contestar o resultado e obter revisão; Citron e Pasquale defendem que sistemas de pontuação automatizados exigem garantias equivalentes às do devido processo (Citron & Pasquale 2014), e na LGPD o direito de pedir revisão está no art. 20 (*Lei n.º 13.709/2018*). **Nesta apresentação:** «cumprimos a LGPD» responde ao 3.3, não ao 5. A pergunta aqui é o que a pessoa afetada pode fazer.

6 • A configuração da decisão

Níveis de automação (*levels of automation*) — automação não é um interruptor. Aplica-se por etapa (aquisição da informação, análise, seleção da ação, execução da ação) e, em cada etapa, num grau que vai do manual ao totalmente automático (Parasuraman, Sheridan & Wickens 2000). **Nesta apresentação:** digam o nível **por passo**, não pelo sistema inteiro.

Humano no circuito (*human in the loop*) — a expressão não tem definição estável, e serve tanto para supervisão real como para um botão de confirmação que ninguém lê. Bainbridge nomeou a ironia central: quanto mais automatizado o sistema, menos prática tem a pessoa, e pior ela fica precisamente quando é chamada a intervir (Bainbridge 1983). **Cuidado:** quando o sistema sugere, as pessoas tendem a seguir a sugestão mesmo contra a evidência à frente delas. É o viés de automação

(Skitka, Mosier & Burdick 1999). **Nesta apresentação:** para cada ponto em que puserem uma pessoa, digam com que informação, em quanto tempo e com que autoridade para dizer não. Sem as três, a pessoa é decorativa.

Revisão de decisão automatizada — o art. 20 da LGPD dá ao titular o direito de pedir revisão de decisões tomadas unicamente com base em tratamento automatizado. **Cuidado:** a exigência de que essa revisão fosse feita **por pessoa natural** foi vetada, e o veto foi mantido pelo Congresso em outubro de 2019: a lei não obriga a que quem revê seja uma pessoa (*Lei n.º 13.709/2018*). **Nesta apresentação:** a revisão humana, se existir no sistema de vocês, é uma decisão de gestão. Assumam-na como tal.

Agente de IA (AI agent) — na formulação clássica, tudo o que percebe o ambiente através de sensores e age sobre ele através de atuadores (*Russell & Norvig 2021*). No uso corrente do mercado a palavra designa outra coisa, sistemas que encadeiam chamadas a ferramentas com autonomia variável, e não há definição estável. **Nesta apresentação:** não usem a palavra sem dizer o que esse agente pode acionar sozinho.

Referências

- Bainbridge (1983)** · Bainbridge, L. «Ironies of automation». *Automatica* 19(6), 775–779. DOI 10.1016/0005-1098(83)90046-8
- Bovens (2007)** · Bovens, M. «Analysing and Assessing Accountability: A Conceptual Framework». *European Law Journal* 13(4), 447–468. DOI 10.1111/j.1468-0386.2007.00378.x
- Buneman, Khanna & Tan (2001)** · Buneman, P., Khanna, S. & Tan, W.-C. «Why and Where: A Characterization of Data Provenance». *Database Theory — ICDT 2001*, LNCS 1973, Springer, 316–330. DOI 10.1007/3-540-44503-X_20
- Citron & Pasquale (2014)** · Citron, D. K. & Pasquale, F. «The Scored Society: Due Process for Automated Predictions». *Washington Law Review* 89(1), 1.
- Cooper (1990)** · Cooper, R. G. «Stage-gate systems: A new tool for managing new products». *Business Horizons* 33(3), 44–54. DOI 10.1016/0007-6813(90)90040-I
- Elkan (2001)** · Elkan, C. «The Foundations of Cost-Sensitive Learning». *Proceedings of the 17th International Joint Conference on Artificial Intelligence (IJCAI)*, 973–978.
- Fawcett (2006)** · Fawcett, T. «An introduction to ROC analysis». *Pattern Recognition Letters* 27(8), 861–874. DOI 10.1016/j.patrec.2005.10.010
- Gama et al. (2014)** · Gama, J., Žliobaitė, I., Bifet, A., Pechenizkiy, M. & Bouchachia, A. «A survey on concept drift adaptation». *ACM Computing Surveys* 46(4), artigo 44. DOI 10.1145/2523813
- Hand (2006)** · Hand, D. J. «Classifier Technology and the Illusion of Progress». *Statistical Science* 21(1), 1–14. DOI 10.1214/088342306000000060
- He & Garcia (2009)** · He, H. & Garcia, E. A. «Learning from Imbalanced Data». *IEEE Transactions on Knowledge and Data Engineering* 21(9), 1263–1284. DOI 10.1109/TKDE.2008.239
- Kapoor & Narayanan (2023)** · Kapoor, S. & Narayanan, A. «Leakage and the reproducibility crisis in machine-learning-based science». *Patterns* 4(9), 100804. DOI 10.1016/j.patter.2023.100804
- Kaufman et al. (2012)** · Kaufman, S., Rosset, S., Perlich, C. & Stitelman, O. «Leakage in Data Mining: Formulation, Detection, and Avoidance». *ACM Transactions on Knowledge Discovery from Data* 6(4), artigo 15. DOI 10.1145/2382577.2382579
- Kimball & Ross (2013)** · Kimball, R. & Ross, M. *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*. 3.ª ed., Wiley.
- Lei n.º 13.709/2018** · Brasil. *Lei Geral de Proteção de Dados Pessoais (LGPD)*, de 14 de agosto de 2018, com as alterações da Lei n.º 13.853/2019. Artigos citados: 7.º (hipóteses de tratamento), 11 (dados sensíveis), 16 (eliminação após o término do tratamento) e 20 (revisão de decisões automatizadas).
- Little & Rubin (2019)** · Little, R. J. A. & Rubin, D. B. *Statistical Analysis with Missing Data*. 3.ª ed., Wiley.
- Nikolopoulos et al. (2011)** · Nikolopoulos, K., Syntetos, A. A., Boylan, J. E., Petropoulos, F. & Assimakopoulos, V. «An aggregate–disaggregate intermittent demand approach (ADIDA) to forecasting: an empirical proposition and analysis». *Journal of the Operational Research Society* 62(3), 544–554.
- Openshaw (1984)** · Openshaw, S. *The Modifiable Areal Unit Problem*. Concepts and Techniques in Modern Geography (CATMOG) 38, Geo Books, Norwich.
- Parasuraman, Sheridan & Wickens (2000)** · Parasuraman, R., Sheridan, T. B. & Wickens, C. D. «A model for types and levels of human interaction with automation». *IEEE Transactions on Systems, Man, and Cybernetics — Part A* 30(3), 286–297. DOI 10.1109/3468.844354
- Provost & Fawcett (2013a)** · Provost, F. & Fawcett, T. «Data Science and its Relationship to Big Data and Data-Driven Decision Making». *Big Data* 1(1), 51–59. DOI 10.1089/big.2013.1508
- Provost & Fawcett (2013b)** · Provost, F. & Fawcett, T. *Data Science for Business*. O'Reilly.
- Ridgway (1956)** · Ridgway, V. F. «Dysfunctional Consequences of Performance Measurements». *Administrative Science Quarterly* 1(2), 240–247. DOI 10.2307/2390989
- Robinson (1950)** · Robinson, W. S. «Ecological Correlations and the Behavior of Individuals». *American Sociological Review* 15(3), 351–357. DOI 10.2307/2087176
- Rubin (1976)** · Rubin, D. B. «Inference and missing data». *Biometrika* 63(3), 581–592. DOI 10.1093/biomet/63.3.581
- Russell & Norvig (2021)** · Russell, S. & Norvig, P. *Artificial Intelligence: A Modern Approach*. 4.ª ed., Pearson.
- Selbst et al. (2019)** · Selbst, A. D., boyd, d., Friedler, S. A., Venkatasubramanian, S. & Vertesi, J. «Fairness and Abstraction in Sociotechnical Systems». *Proceedings of the Conference on Fairness, Accountability, and Transparency*, 59–68. DOI 10.1145/3287560.3287598
- Skitka, Mosier & Burdick (1999)** · Skitka, L. J., Mosier, K. L. & Burdick, M. «Does automation bias decision-making?». *International Journal of Human-Computer Studies* 51(5), 991–1006. DOI 10.1006/ijhc.1999.0252
- W3C PROV-DM (2013)** · Moreau, L. & Missier, P. (eds.) *PROV-DM: The PROV Data Model*. W3C Recommendation, 30 de abril de 2013.
- Wang & Strong (1996)** · Wang, R. Y. & Strong, D. M. «Beyond Accuracy: What Data Quality Means to Data Consumers». *Journal of Management Information Systems* 12(4), 5–33. DOI 10.1080/07421222.1996.11518099